

Perbandingan Metode Imputasi Missing Value terhadap Kinerja Model Klasifikasi pada Dataset Diabetes



Dosen Pengampu:

Meida Cahyo Untoro, S.Kom., M.Kom.

Mata Kuliah:

Penambangan Data IF-32025

Semester:

06

Disusun Oleh: Kelompok 05

Topik: Missing Value

Najlatika	123140078
Bening Apni Prameswari	123140089
Falent Antonius Panjaitan	123140124
Raditya Alrasyid Nugroho	123140125
Raisya Syifa Saleh	123140169
Muhamad Arif Ardani	123140186

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
2026**

DAFTAR ISI

DAFTAR ISI.....	2
BAB I.....	3
PENDAHULUAN.....	3
1.1 Latar Belakang.....	3
1.2 Rumusan Masalah.....	4
1.3 Tujuan Penelitian.....	4
1.4 Batasan Masalah.....	5
BAB II.....	6
TINJAUAN PUSTAKA.....	6
2.1 Data Mining dan Preprocessing.....	6
2.2 Missing Value.....	6
2.3 Metode Imputasi.....	7
2.4 Metrik Evaluasi.....	7
2.5 Penelitian Terkait.....	8
BAB III	
METODOLOGI PENELITIAN.....	9
3.1 Alur Penelitian.....	9
3.2 Deskripsi Dataset.....	9
3.3 Prosedur Eksperimen.....	10
3.3.1 Pembagian Data (Train-Test Split).....	10
3.3.2 Metode Missing Value yang Digunakan.....	16
3.3.3 Algoritma Klasifikasi.....	17
3.3.4 Metrik Evaluasi.....	17
BAB IV.....	19
HASIL & PEMBAHASAN.....	19
4.1 Eksplorasi Data (EDA).....	19
4.1.1 Gambaran Umum Dataset.....	19
4.1.2 Distribusi Fitur.....	20
4.1.3 Distribusi Kelas Target.....	21
4.2 EDA Spesifikasi Topik.....	22
4.2.1 Visualisasi Pola Missing.....	22
4.3 Implementasi Imputasi.....	23
4.4 Hasil Perbandingan Metode.....	24
4.4.1 Tabel Perbandingan Peforma.....	24
4.4.2 Visualisasi Perbandingan.....	25
4.5 Pembahasan.....	28
DAFTAR PUSTAKA.....	29

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi di bidang kesehatan telah mendorong pemanfaatan data dalam jumlah besar untuk mendukung pengambilan keputusan klinis. Salah satu sumber utama data tersebut adalah *electronic health records* (EHR), yang menyimpan berbagai informasi pasien dalam bentuk digital. Pemanfaatan data ini memungkinkan penerapan teknik *machine learning* dan *data mining* untuk meningkatkan kualitas diagnosis serta prediksi penyakit secara lebih akurat. Dalam proses tersebut, tahap *preprocessing data* menjadi sangat penting karena kualitas data yang digunakan akan sangat mempengaruhi performa model yang dihasilkan (Jia et al., 2022).

Namun demikian, *dataset* kesehatan di dunia nyata seringkali mengandung *missing values* atau data yang hilang. Permasalahan ini dapat disebabkan oleh berbagai faktor seperti kesalahan pencatatan, kegagalan alat medis, maupun proses pengumpulan data yang tidak sempurna (Joel et al., 2025). Keberadaan *missing values* menjadi tantangan serius karena sebagian besar algoritma *machine learning* membutuhkan data yang lengkap untuk menghasilkan model dengan tingkat akurasi yang optimal. Selain itu, penanganan data yang tidak tepat, seperti penghapusan data atau imputasi sederhana menggunakan nilai rata-rata, dapat menyebabkan hilangnya informasi penting dan menghasilkan data yang kurang representatif (Jia et al., 2022).

Berbagai metode imputasi telah dikembangkan untuk mengatasi permasalahan tersebut seperti *Mean Imputation*, *K-Nearest Neighbor* (KNN), dan *MICE*, yang bertujuan untuk meningkatkan kualitas data sebelum digunakan dalam proses klasifikasi (Joel et al., 2025). Meskipun demikian, sebagian besar penelitian hanya berfokus pada penggunaan satu metode tertentu tanpa melakukan perbandingan secara komprehensif. Hal ini menyebabkan kurangnya pemahaman mengenai metode imputasi mana yang paling efektif dalam meningkatkan kinerja model klasifikasi, khususnya pada *dataset* kesehatan seperti diabetes, yang memiliki karakteristik data kompleks dan berpengaruh langsung terhadap hasil prediksi (Jia et al., 2022).

Berdasarkan permasalahan tersebut, penelitian ini dilakukan untuk membandingkan beberapa metode imputasi *missing values* pada *dataset* diabetes serta menganalisis pengaruhnya terhadap kinerja model klasifikasi. Metode imputasi yang

digunakan meliputi *Mean Imputation*, *K-Nearest Neighbor* (KNN), dan *MICE*, yang kemudian dievaluasi menggunakan model klasifikasi *Random Forest* dengan metrik *accuracy*, *recall*, dan *F1-score*. Melalui penelitian ini, diharapkan dapat diperoleh metode imputasi yang paling efektif dalam meningkatkan kualitas data dan performa model, sehingga dapat mendukung pengembangan sistem prediksi penyakit diabetes yang lebih akurat dan andal.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah :

1. Bagaimana menangani *missing values* pada *dataset* diabetes agar kualitas data tetap terjaga untuk proses analisis?
2. Bagaimana melakukan perbandingan beberapa metode imputasi *missing values* dalam menghasilkan data yang lebih representatif?
3. Bagaimana pengaruh masing-masing metode imputasi terhadap kinerja model klasifikasi dalam prediksi penyakit diabetes?
4. Bagaimana kinerja model klasifikasi *Random Forest* pada *dataset* yang telah melalui proses imputasi dengan metode yang berbeda?
5. Bagaimana evaluasi performa model klasifikasi berdasarkan metrik *accuracy*, *recall*, dan *F1-score* pada masing-masing metode imputasi?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah :

1. Menganalisis dan menangani *missing values* pada *dataset* diabetes menggunakan metode imputasi yang sesuai.
2. Membandingkan beberapa metode imputasi *missing values* untuk mengetahui metode yang paling efektif.
3. Mengevaluasi pengaruh metode imputasi terhadap kinerja model klasifikasi dalam prediksi penyakit diabetes.
4. Menganalisis kinerja model klasifikasi *Random Forest* pada *dataset* yang telah melalui proses imputasi dengan metode yang berbeda.
5. Mengevaluasi performa model klasifikasi berdasarkan metrik *accuracy*, *recall*, dan *F1-score* pada masing-masing metode imputasi.

1.4 Batasan Masalah

Batasan masalah dalam penelitian ini adalah :

1. *Dataset* yang digunakan dalam penelitian ini adalah Pima Indians Diabetes *Database* yang diperoleh dari Kaggle.
2. Metode imputasi yang dibandingkan dibatasi pada beberapa metode, yaitu *Mean Imputation*, *K-Nearest Neighbor* (KNN), dan *MICE*.
3. Model klasifikasi yang digunakan dibatasi pada algoritma *Random Forest* sebagai model utama dalam evaluasi kinerja.
4. Evaluasi kinerja model dilakukan menggunakan metrik *accuracy*, *recall*, *F1-score*.

BAB II

TINJAUAN PUSTAKA

2.1 Data Mining dan Preprocessing

Data mining merupakan proses untuk menemukan pola atau informasi penting dari sekumpulan data dalam jumlah besar dengan memanfaatkan teknik statistik, *machine learning*, dan basis data (Han et al., 2012). Dalam bidang kesehatan, *data mining* banyak digunakan untuk membantu proses diagnosis penyakit serta meningkatkan akurasi prediksi berdasarkan data historis yang tersedia. Sebelum data dianalisis, diperlukan tahap awal yang disebut *data preprocessing*. Tahap ini bertujuan untuk membersihkan dan mempersiapkan data agar lebih siap digunakan dalam proses analisis. *Preprocessing* biasanya mencakup beberapa langkah seperti pembersihan data, transformasi data, dan seleksi fitur (Jena & Dehuri, 2022). Dalam praktiknya, data yang digunakan seringkali belum dalam kondisi ideal. Masalah seperti data kosong (*missing value*), *noise*, dan inkonsistensi sering muncul. Jika tidak ditangani dengan baik, hal ini dapat menurunkan performa model *machine learning*. Oleh karena itu, *preprocessing* menjadi tahap penting agar hasil analisis menjadi lebih akurat dan dapat dipercaya (Jia et al., 2022).

2.2 Missing Value

Missing value adalah kondisi ketika suatu atribut dalam *dataset* tidak memiliki nilai. Permasalahan ini sering ditemukan pada data dunia nyata, terutama pada data kesehatan seperti *Electronic Health Records* (EHR). Ada beberapa penyebab munculnya *missing value*, seperti kesalahan pengukuran, data yang tidak tercatat, kerusakan alat, atau responden yang tidak memberikan jawaban (Joel et al., 2025).

Secara umum, *missing value* dibagi menjadi tiga jenis, yaitu:

- *Missing Completely at Random* (MCAR) data hilang secara acak dan tidak berkaitan dengan variabel lain
- *Missing at Random* (MAR) data hilang dipengaruhi oleh variabel lain
- *Missing Not at Random* (MNAR) data hilang dipengaruhi oleh nilai itu sendiri

(Psychogyios et al., 2023; Jena & Dehuri, 2022).

Keberadaan *missing value* dapat berdampak besar terhadap performa model. *Dataset* yang tidak lengkap bisa menyebabkan hasil prediksi menjadi kurang akurat dan sulit digeneralisasi (Alnowaiser, 2024).

2.3 Metode Imputasi

Imputasi adalah teknik yang digunakan untuk mengisi nilai yang hilang dalam *dataset* dengan nilai tertentu agar data tetap dapat digunakan dalam proses analisis (van Buuren, 2018).

Beberapa metode imputasi yang umum digunakan dijelaskan pada tabel berikut:

Metode	Prinsip Kerja	Kelebihan	Kekurangan
<i>Mean Imputation</i>	Mengisi nilai yang hilang dengan rata-rata dari fitur	Sederhana dan cepat	Mengurangi variansi dan sensitif terhadap <i>outlier</i>
<i>KNN Imputer</i>	Mengisi nilai berdasarkan <i>k-nearest neighbors</i>	Mempertimbangkan hubungan antar fitur	Sensitif terhadap skala dan membutuhkan waktu komputasi lebih lama
<i>MICE</i>	Melakukan imputasi <i>multivariate</i> secara iteratif menggunakan model regresi	Mampu menangkap hubungan yang lebih kompleks antar fitur	Komputasinya lebih tinggi dan penerapannya lebih kompleks

(Sumber: Joel et al., 2025; van Buuren, 2018; scikit-learn, 2024)

Metode sederhana seperti mean dan median cukup mudah digunakan, tetapi memiliki keterbatasan karena tidak mempertimbangkan hubungan antar fitur. Sementara itu, metode seperti KNN dan *MICE* mampu memberikan hasil yang lebih baik karena mempertimbangkan pola dalam data (Troyanskaya et al., 2001). Selain itu, beberapa penelitian terbaru juga menggunakan pendekatan berbasis *machine learning* seperti *MissForest*, *autoencoder*, dan GAN yang mampu menangani hubungan kompleks antar variabel secara lebih efektif (Psychogyios et al., 2023)

2.4 Metrik Evaluasi

Evaluasi model dilakukan menggunakan beberapa metrik untuk mengukur performa klasifikasi.

- *Accuracy* mengukur seberapa banyak prediksi yang benar dari seluruh data
- *Recall* mengukur kemampuan model dalam mendeteksi data positif
- *F1-Score* kombinasi antara *precision* dan *recall*

(Joel et al., 2025).

Dalam beberapa penelitian, penggunaan metode imputasi seperti Mean terbukti mampu meningkatkan nilai *accuracy*, *recall*, *F1 Score* dibandingkan data yang tidak diproses terlebih dahulu (Alnowaiser, 2024).

2.5 Penelitian Terkait

Penelitian terkait *missing value* telah banyak dilakukan, terutama pada *dataset* kesehatan.


1. Alnowaiser (2024) mengembangkan model prediksi diabetes dengan menggunakan *KNN Imputer* yang dikombinasikan dengan metode *ensemble*. Hasil penelitian menunjukkan peningkatan performa dengan akurasi mencapai 97.49% .
2. Joel et al. (2025) melakukan perbandingan beberapa metode imputasi seperti Mean, Median, KNN, dan *MICE*. Hasilnya menunjukkan bahwa metode berbasis *machine learning* seperti *MissForest* dan *MICE* memberikan hasil terbaik berdasarkan metrik RMSE dan MAE .
3. Psychogyios et al. (2023) mengusulkan metode imputasi berbasis *deep learning* seperti *autoencoder* dan GAN. Pendekatan ini terbukti lebih mampu menangkap hubungan kompleks dalam data dibandingkan metode tradisional .
4. Jena dan Dehuri (2022) mengembangkan *framework* yang menggabungkan *Decision Tree* dan SVM untuk proses imputasi dan klasifikasi. Penelitian ini menunjukkan bahwa metode berbasis *machine learning* lebih efektif dibandingkan metode statistik sederhana .
5. Jia et al. (2022) mengusulkan metode *PE_DIM* yang menggabungkan teknik imputasi dan *ensemble learning* untuk menangani *missing value* dan *data imbalance* secara bersamaan. Metode ini mampu meningkatkan akurasi klasifikasi hingga 94.53% .

Secara umum, dari beberapa penelitian tersebut dapat disimpulkan bahwa metode imputasi yang lebih kompleks dan mempertimbangkan hubungan antar fitur cenderung memberikan hasil yang lebih baik dibandingkan metode sederhana.

BAB III

METODOLOGI PENELITIAN

3.1 Alur Penelitian



Gambar 1. Alur Penelitian Preprocessing Missing Value

Untuk memastikan validitas model dan tidak adanya kesalahan data, jalur penelitian dalam laporan ini dirancang secara sistematis. Proses dimulai dengan pengumpulan data menggunakan Kaggle, dan kemudian digunakan EDA untuk mempelajari karakteristik dataset. Train-Test Split, dimana data dipisahkan sebelum preprocessing, melakukan tahap penting. Hal ini bertujuan agar proses imputasi data pelatihan tidak memasukkan informasi dari tes data. Terakhir, model dievaluasi untuk mengetahui hasil perbandingan metode imputasi yang objektif menggunakan data tes awal.

3.2 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini adalah Pima Indians Diabetes Database yang diperoleh dari Kaggle. Dataset ini terdiri dari:

- Jumlah sampel : 768 baris
- Jumlah fitur : 9 kolom (8 fitur numerik sebagai prediktor dan 1 variabel target)
- Variabel target : Outcome — [0: Tidak Diabetes, 1 : Diabetes]
- Distribusi kelas : Kelas 0 = 500 sampel (65.1%), Kelas 1 = 268 sampel (34.9%)
- Imbalance Ratio : 1 : 1.86
- Missing Values : Berdasarkan observasi awal, dataset ini memiliki missing value tersembunyi yang dipresentasikan dengan nilai 0 pada fitur Glucose, BloodPressure, SkinThickness, Insulin, dan BMI.

Tabel 1. Deskripsi Fitur Dataset

No.	Nama Fitur	Tipe	Deskripsi	Missing (%)
1	Pregnancies	Numerik	Jumlah kehamilan yang pernah dialami	0%
2	Glucose	Numerik	Konsentrasi Glukosa Plasma	0.65%
3	BloodPressure	Numerik	Tekanan darah diastolik	4.56%
4	SkinThickness	Numerik	Ketebalan lipatan kulit trisep	29.56%
5	Insulin	Numerik	Insulin serum 2 jam	48.70%
6	BMI	Numerik	Indeks massa tubuh	1.43%
7	DiabetesPedigree	Numerik	Skor riwayat genetik diabetes	0%
8	Age	Numerik	Usia Pasien	0%
9	Outcome	Numerik	Status diagnosa (target)	0%

3.3 Prosedur Eksperimen

3.3.1 Pembagian Data (Train-Test Split)

Data dibagi menjadi dua bagian utama: Training Set (80%) dan Test Set (20%). Pembagian dilakukan menggunakan teknik Stratified Sampling untuk memastikan proporsi kelas target (Diabetes vs Non-Diabetes) tetap seimbang di kedua set. Penting untuk dicatat bahwa pembagian data dilakukan sebelum proses imputasi. Hal ini bertujuan agar informasi statistik dari data testing tidak mempengaruhi pengisian nilai pada data training, sehingga evaluasi model tetap objektif.

Python

```
# =====
# IMPORT LIBRARY
# =====

import pandas as pd
```

```

import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.impute import SimpleImputer, KNNImputer, IterativeImputer
from sklearn.experimental import enable_iterative_imputer
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score

import warnings
warnings.filterwarnings('ignore')

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.impute import SimpleImputer, KNNImputer, IterativeImputer
from sklearn.experimental import enable_iterative_imputer
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score

import warnings
warnings.filterwarnings('ignore')

# =====
# 3.3 PROSEDUR EKSPERIMEN
# =====

# 1. Split Feature dan Target
X = df.drop('Outcome', axis=1)
y = df['Outcome']

# 2. Split Train & Test (80:20)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)

# 3. List Metode Imputasi untuk Dibandingkan (Mean, KNN, MICE)

```

```

imputers = {
    'Mean': SimpleImputer(strategy='mean'),
    'KNN': KNNImputer(n_neighbors=5),
    'MICE': IterativeImputer(max_iter=20, random_state=42)
}

```

```

results = []

```

4. Loop Perbandingan

```

for name, imputer in imputers.items():

```

```

    # Proses Imputasi

```

```

    X_train_imp = imputer.fit_transform(X_train)

```

```

    X_test_imp = imputer.transform(X_test)

```

```

    # Model Random Forest

```

```

    clf = RandomForestClassifier(random_state=42)

```

```

    clf.fit(X_train_imp, y_train)

```

```

    # Evaluasi

```

```

    y_pred = clf.predict(X_test_imp)

```

```

    results.append({

```

```

        'Metode': name,

```

```

        'Accuracy': accuracy_score(y_test, y_pred),

```

```

        'F1-Score': f1_score(y_test, y_pred),

```

```

        'Recall': recall_score(y_test, y_pred)

```

```

    })

```

```

# Tampilkan Hasil Akhir

```

```

df_hasil = pd.DataFrame(results)

```

```

print("\n===== HASIL PERBANDINGAN BAB 3 =====")

```

```

display(df_hasil)

```

===== HASIL PERBANDINGAN BAB 3 =====

	Metode	Accuracy	F1-Score	Recall
0	Mean	0.75974	0.633663	0.592593
1	KNN	0.75974	0.633663	0.592593
2	MICE	0.75974	0.633663	0.592593

Python

```
# =====  
# LOAD DATA + INFO DASAR  
# =====  
  
# Link dataset Pima Indians Diabetes (Raw GitHub)  
url = "https://raw.githubusercontent.com/jbrownlee/Datasets/master/pima-indians-diabetes.data.csv"  
  
# Nama-nama kolom sesuai deskripsi dataset di Kaggle  
column_names = ['Pregnancies', 'Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI',  
                'DiabetesPedigreeFunction', 'Age', 'Outcome']  
  
# Load data langsung dari URL  
df = pd.read_csv(url, names=column_names)  
  
# Identifikasi Missing Value Tersembunyi (Nilai 0 diubah jadi NaN)  
cols_with_zeros = ['Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI']  
df[cols_with_zeros] = df[cols_with_zeros].replace(0, np.nan)  
  
print("===== HEAD =====")  
display(df.head())  
  
print("\n===== INFO =====")  
df.info()  
  
print("\n===== DESCRIBE (Setelah Replace 0 ke NaN) =====")  
display(df.describe())  
  
print("\n===== MISSING VALUE TERDETEKSI =====")  
display(df.isnull().sum())
```

```
===== HEAD =====
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148.0	72.0	35.0	NaN	33.6	0.627	50	1
1	1	85.0	66.0	29.0	NaN	26.6	0.351	31	0
2	8	183.0	64.0	NaN	NaN	23.3	0.672	32	1
3	1	89.0	66.0	23.0	94.0	28.1	0.167	21	0
4	0	137.0	40.0	35.0	168.0	43.1	2.288	33	1

```
===== INFO =====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Pregnancies                          768 non-null    int64
1   Glucose                             763 non-null    float64
2   BloodPressure                       733 non-null    float64
3   SkinThickness                      541 non-null    float64
4   Insulin                            394 non-null    float64
5   BMI                                757 non-null    float64
6   DiabetesPedigreeFunction            768 non-null    float64
7   Age                                768 non-null    int64
8   Outcome                            768 non-null    int64
dtypes: float64(6), int64(3)
memory usage: 54.1 KB
```

```
===== DESCRIBE (Setelah Replace 0 ke NaN) =====
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	763.000000	733.000000	541.000000	394.000000	757.000000	768.000000	768.000000	768.000000
mean	3.845052	121.686763	72.405184	29.153420	155.548223	32.457464	0.471876	33.240885	0.348958
std	3.369578	30.535641	12.382158	10.476982	118.775855	6.924988	0.331329	11.760232	0.476951
min	0.000000	44.000000	24.000000	7.000000	14.000000	18.200000	0.078000	21.000000	0.000000
25%	1.000000	99.000000	64.000000	22.000000	76.250000	27.500000	0.243750	24.000000	0.000000
50%	3.000000	117.000000	72.000000	29.000000	125.000000	32.300000	0.372500	29.000000	0.000000
75%	6.000000	141.000000	80.000000	36.000000	190.000000	36.600000	0.626250	41.000000	1.000000
max	17.000000	199.000000	122.000000	99.000000	846.000000	67.100000	2.420000	81.000000	1.000000

```
===== MISSING VALUE TERDETEKSI =====
```

	0
Pregnancies	0
Glucose	5
BloodPressure	35
SkinThickness	227
Insulin	374
BMI	11
DiabetesPedigreeFunction	0
Age	0
Outcome	0

```
dtype: int64
```

Python

```
# =====
# VISUALISASI MISSING VALUE
```

```

# =====
import matplotlib.pyplot as plt
import seaborn as sns

# 1. Menghitung statistik missing value
mv_count = df.isnull().sum()
mv_percent = (mv_count / len(df)) * 100
mv_df = pd.DataFrame({'Fitur': mv_count.index, 'Jumlah': mv_count.values, 'Persentase':
mv_percent.values})
mv_df = mv_df[mv_df['Jumlah'] > 0].sort_values(by='Persentase', ascending=False)

# --- Visualisasi A: Bar Chart Persentase dan Visualisasi B: Heatmap Bersih (Side-by-Side)
fig, axes = plt.subplots(1, 2, figsize=(20, 6)) # 1 row, 2 columns for side-by-side plots

# Subplot 1: Bar Chart Persentase
ax = sns.barplot(x='Persentase', y='Fitur', data=mv_df, palette='Reds_r', ax=axes[0])


# Tambahkan label angka di samping bar agar presisi
for p in ax.patches:
    ax.annotate(f'{p.get_width():.1f}%',
                (p.get_width(), p.get_y() + p.get_height() / 2.),
                ha='left', va='center', xytext=(5, 0), textcoords='offset points', fontsize=10)

axes[0].set_title('Proporsi Missing Value per Fitur (Pima Indians)', fontsize=14, pad=15)
axes[0].set_xlabel('Persentase Data yang Hilang (%)', fontsize=12)
axes[0].set_ylabel('Fitur Medis', fontsize=12)
axes[0].set_xlim(0, max(mv_df['Persentase']) + 15) # Beri ruang untuk teks
axes[0].grid(axis='x', linestyle='--', alpha=0.6)

# Subplot 2: Heatmap Bersih (Hanya jika perlu pola distribusi)
# Warna: Abu-abu Muda (Ada data) dan Merah Marun (Data Hilang)
sns.heatmap(df.isnull(), yticklabels=False, cbar=True, cmap=['#f0f0f0', '#8b0000'], ax=axes[1])
axes[1].set_title('Peta Lokasi Missing Value (Merah = Kosong)', fontsize=14, pad=15)
axes[1].set_xticks(ticks=np.arange(len(df.columns)), labels=df.columns, rotation=45, ha='right')

plt.tight_layout()
plt.show()

```



3.3.2 Metode Missing Value yang Digunakan

Dalam penelitian ini digunakan beberapa metode imputasi untuk menangani missing value (nilai 0 yang telah diubah menjadi NaN) pada dataset diabetes:

1. Mean Imputation — dilakukan dengan mengisi nilai kosong menggunakan rata-rata dari fitur terkait dengan parameter `strategy='mean'`. Metode ini dipilih karena kesederhanaannya dan sebagai titik baseline untuk perbandingan dengan metode yang lebih kompleks.
2. KNN Imputer — bekerja dengan mengidentifikasi $k=5$ tetangga terdekat berdasarkan jarak Euclidean untuk mengisi nilai yang hilang menggunakan rata-rata tertimbang dari tetangga tersebut. Metode ini dipilih karena mempertimbangkan hubungan antar fitur dalam pengisian nilai, yang dapat menghasilkan imputasi yang lebih kontekstual.

3. MICE (Multiple Imputation by Chained Equations) — dilakukan dengan memodelkan setiap fitur yang memiliki missing value sebagai fungsi dari fitur lainnya melalui proses regresi iteratif. Dengan parameter `max_iter=20` dan `random_state=42`, metode ini dipilih karena kemampuannya menangkap hubungan korelasi multivariat yang kompleks antar indikator klinis, sehingga struktur keterkaitan internal antar variabel tetap terjaga.
4. Baseline — Sebagai pembandingan, model juga diuji menggunakan data asli tanpa proses imputasi (menghapus baris yang memiliki nilai kosong), untuk mengukur dampak sebenarnya dari penanganan *missing value*.

Semua metode imputasi ini diterapkan hanya pada training set untuk mencegah terjadinya data leakage.

3.3.3 Algoritma Klasifikasi

Algoritma klasifikasi yang digunakan sebagai evaluator utama dalam penelitian ini adalah Random Forest Classifier (Breiman, 2001). Model ini diimplementasikan menggunakan parameter default dari pustaka `scikit-learn`, yaitu dengan jumlah tree (`n_estimators`) sebanyak 100 dan `random_state=42` untuk menjamin konsistensi hasil eksperimen. Pemilihan Random Forest didasarkan pada karakteristiknya sebagai algoritma ensemble learning yang memiliki tingkat resistensi tinggi terhadap overfitting, terutama pada dataset dengan ukuran kecil hingga menengah. Selain itu, algoritma ini mampu menangani hubungan non-linear antar fitur medis secara efektif dan tidak memerlukan feature scaling yang ketat (seperti normalisasi atau standarisasi) untuk berfungsi dengan optimal, sehingga menjadikannya model yang sangat robust untuk mengevaluasi dampak dari berbagai metode imputasi yang diterapkan.

3.3.4 Metrik Evaluasi

Untuk mengukur kinerja model klasifikasi setelah penerapan berbagai metode imputasi, digunakan beberapa metrik evaluasi sebagai berikut:

- Accuracy yang mengukur proporsi prediksi benar secara keseluruhan terhadap total data. Meskipun umum digunakan, akurasi saja tidak cukup untuk dataset ini karena adanya ketidakseimbangan kelas (imbalance) antara pasien sehat dan diabetes.

- Recall yang mengukur rata-rata kemampuan model dalam mendeteksi kembali seluruh sampel pada setiap kelas. Dalam domain medis, recall sangat krusial untuk mendeteksi kelas minoritas (pasien diabetes), karena kegagalan deteksi (false negative) berisiko tinggi bagi keselamatan pasien.
- F1-Score yang merupakan rata-rata harmonik antara precision dan recall. Metrik ini digunakan sebagai metrik utama untuk menentukan metode imputasi terbaik karena memberikan keseimbangan antara ketepatan dan kepekaan model, yang jauh lebih informatif daripada akurasi pada dataset yang tidak seimbang.

Metrik utama yang digunakan adalah F1-Score karena mampu menyeimbangkan precision dan recall. F1-Score dipilih sebagai metrik evaluasi utama dalam penelitian ini karena kemampuannya dalam memberikan keseimbangan objektif antara precision dan recall melalui perhitungan rata-rata harmonik, yang sangat krusial pada dataset Pima Indians Diabetes yang memiliki distribusi kelas tidak seimbang (imbalanced). Dalam konteks diagnosis medis, F1-Score memastikan bahwa model tidak hanya mengejar akurasi tinggi secara keseluruhan, tetapi juga efektif dalam meminimalkan kesalahan fatal baik berupa false positive (pasien sehat yang salah didiagnosa diabetes) maupun false negative (pasien diabetes yang tidak terdeteksi), sehingga memberikan representasi performa model yang lebih jujur, reliabel, dan aman untuk diimplementasikan dibandingkan hanya mengandalkan nilai akurasi semata.

BAB IV

HASIL & PEMBAHASAN

4.1 Eksplorasi Data (EDA)

4.1.1 Gambaran Umum Dataset

Dataset terdiri dari 768 baris dan 9 kolom

5 Data Teratas:

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI \
0	6	148	72	35	0	33.6
1	1	85	66	29	0	26.6
2	8	183	64	0	0	23.3
3	1	89	66	23	94	28.1
4	0	137	40	35	168	43.1

	DiabetesPedigreeFunction	Age	Outcome
0	0.627	50	1
1	0.351	31	0
2	0.672	32	1
3	0.167	21	0
4	2.288	33	1

Statistik Deskriptif:

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin \
count	768.000000	768.000000	768.000000	768.000000	768.000000
mean	3.845052	120.894531	69.105469	20.536458	79.799479
std	3.369578	31.972618	19.355807	15.952218	115.244002
min	0.000000	0.000000	0.000000	0.000000	0.000000
25%	1.000000	99.000000	62.000000	0.000000	0.000000
50%	3.000000	117.000000	72.000000	23.000000	30.500000
75%	6.000000	140.250000	80.000000	32.000000	127.250000
max	17.000000	199.000000	122.000000	99.000000	846.000000


	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	768.000000	768.000000	768.000000
mean	31.992578	0.471876	33.240885	0.348958
std	7.884160	0.331329	11.760232	0.476951
min	0.000000	0.078000	21.000000	0.000000
25%	27.300000	0.243750	24.000000	0.000000
50%	32.000000	0.372500	29.000000	0.000000
75%	36.600000	0.626250	41.000000	1.000000
max	67.100000	2.420000	81.000000	1.000000

Dataset yang digunakan dalam penelitian ini adalah dataset Pima Indians Diabetes yang diperoleh dari sumber publik. Dataset ini terdiri dari 768 sampel (baris) dan 9 fitur (kolom), yang mencakup 8 fitur independen dan 1 variabel target (Outcome). Berdasarkan statistik deskriptif, setiap fitur memiliki karakteristik distribusi yang berbeda. Sebagai contoh, fitur Glucose memiliki rentang nilai dari sekitar 0 hingga 199 dengan rata-rata sekitar 120, yang menunjukkan variasi kadar glukosa pada pasien. Fitur BMI memiliki nilai rata-rata sekitar 32, yang menunjukkan bahwa sebagian besar sampel berada pada kategori overweight hingga obesitas.

Selain itu, beberapa fitur seperti Insulin dan SkinThickness memiliki nilai minimum 0, yang secara medis tidak valid. Hal ini mengindikasikan adanya missing

value terselubung dalam dataset yang perlu ditangani pada tahap preprocessing. Secara umum, statistik deskriptif memberikan gambaran awal mengenai distribusi data dan membantu dalam mengidentifikasi potensi permasalahan seperti missing value dan outlier sebelum dilakukan analisis lebih lanjut. Dataset ini cocok digunakan untuk penelitian klasifikasi karena memiliki variabel target biner yang jelas, yaitu apakah pasien terdiagnosis diabetes atau tidak.

4.1.2 Distribusi Fitur




Berdasarkan gambar terlihat bahwa sebagian besar fitur pada dataset ini tidak berdistribusi normal dan cenderung memiliki kemencengan (skewed), baik ke kanan maupun ke kiri. Fitur Pregnancies terlihat right-skewed dengan nilai skewness sekitar 0.90. Artinya, sebagian besar data berada pada nilai rendah, tetapi ada beberapa nilai tinggi yang cukup jauh dari mayoritas. Sementara itu, Glucose memiliki distribusi yang relatif lebih seimbang dengan skewness 0.17, sehingga bisa dibilang mendekati distribusi normal. Untuk BloodPressure dan BMI, distribusinya cenderung left-skewed dengan nilai skewness masing-masing -1.84 dan -0.43. Ini menunjukkan bahwa banyak data berada pada nilai yang cukup tinggi.

Di sisi lain, fitur seperti Insulin dan DiabetesPedigreeFunction memiliki right-skewed yang cukup ekstrem (2.27 dan 1.92), yang menandakan adanya

nilai-nilai besar yang cukup jauh dari data lainnya. Fitur Age juga menunjukkan pola right-skewed (1.13), yang berarti sebagian besar pasien berada di usia lebih muda. Sedangkan SkinThickness terlihat cukup mendekati normal (0.11), walaupun masih ada nilai nol yang cukup banyak. Dari sini bisa dilihat bahwa data tidak sepenuhnya ideal, terutama karena adanya distribusi yang tidak normal dan kemungkinan outlier. Kondisi ini bisa memengaruhi hasil imputasi, terutama untuk metode sederhana seperti mean. Oleh karena itu, metode yang lebih mempertimbangkan hubungan antar data seperti KNN atau MICE kemungkinan akan memberikan hasil yang lebih baik.

4.1.3 Distribusi Kelas Target




Berdasarkan gambar distribusi kelas target, terlihat bahwa dataset memiliki ketidakseimbangan kelas (class imbalance) antara kelas 0 (tidak diabetes) dan kelas 1 (diabetes). Jumlah sampel pada kelas 0 sebanyak 500 data atau sekitar 65,1%, sedangkan kelas 1 berjumlah 268 data atau sekitar 34,9%. Hal ini juga diperkuat dengan nilai Imbalance Ratio (IR) sebesar 1,87, yang menunjukkan bahwa jumlah data pada kelas mayoritas hampir dua kali lipat dibandingkan kelas minoritas.

Visualisasi dalam bentuk diagram batang memperlihatkan perbedaan jumlah yang cukup signifikan antara kedua kelas, sementara diagram pie chart menegaskan proporsi distribusi tersebut secara persentase. Ketidakseimbangan ini dapat berdampak pada performa model machine learning, di mana model cenderung lebih bias terhadap kelas mayoritas dan kurang optimal dalam mendeteksi kelas minoritas (pasien diabetes). Oleh karena itu, diperlukan penanganan khusus seperti teknik resampling (misalnya SMOTE atau undersampling) atau penggunaan metode evaluasi yang tepat agar model tetap mampu mengenali kedua kelas secara seimbang.

4.2 EDA Spesifikasi Topik

4.2.1 Visualisasi Pola Missing




Berdasarkan gambar pola missing value pada dataset, terlihat bahwa tidak semua fitur memiliki data yang lengkap. Melalui missing value matrix, dapat diamati bahwa beberapa variabel seperti Glucose, BloodPressure, SkinThickness, Insulin, dan BMI memiliki nilai yang hilang, yang dalam konteks dataset ini umumnya direpresentasikan sebagai nilai 0. Di antara fitur-fitur tersebut, SkinThickness dan Insulin tampak memiliki jumlah missing value paling banyak, ditunjukkan oleh banyaknya garis kosong pada kolom tersebut. Sementara itu, variabel lain seperti Pregnancies, DiabetesPedigreeFunction, Age, dan Outcome relatif tidak memiliki missing value dan datanya lebih lengkap. Selanjutnya, pada heatmap korelasi antar missing value terlihat adanya hubungan antar fitur yang mengalami kehilangan data. Korelasi tertinggi terlihat antara SkinThickness dan Insulin dengan nilai sekitar 0,7, yang menunjukkan bahwa jika satu fitur bernilai hilang, maka kemungkinan besar fitur lainnya juga hilang.

Selain itu, terdapat korelasi rendah hingga sedang pada beberapa pasangan fitur lain seperti BloodPressure dengan BMI atau SkinThickness, yang mengindikasikan adanya pola tertentu dalam kehilangan data. Namun, sebagian besar korelasi masih tergolong lemah, sehingga missing value tidak sepenuhnya saling bergantung antar variabel. Secara keseluruhan, pola ini menunjukkan bahwa missing value pada dataset tidak terjadi secara sepenuhnya acak (not completely random), terutama karena adanya korelasi pada beberapa fitur tertentu. Oleh karena itu, penanganan missing value tidak cukup hanya dengan metode sederhana, tetapi perlu mempertimbangkan teknik imputasi yang lebih baik seperti KNN Imputer atau Iterative Imputer agar hubungan antar variabel tetap terjaga dan tidak mengurangi kualitas data untuk proses pemodelan selanjutnya.


4.3 Implementasi Imputasi

Distribusi Glucose Sebelum vs Sesudah Imputasi (Mean)




Distribusi BloodPressure Sebelum vs Sesudah Imputasi (Mean)


Distribusi BloodPressure Sebelum vs Sesudah Imputasi (Mean)




Distribusi SkinThickness Sebelum vs Sesudah Imputasi (Mean)



Distribusi Insulin Sebelum vs Sesudah Imputasi (Mean)



Distribusi BMI Sebelum vs Sesudah Imputasi (Mean)



Berdasarkan visualisasi distribusi data sebelum dan sesudah imputasi menggunakan metode mean, terlihat bahwa imputasi memberikan dampak yang berbeda dibandingkan metode KNN, terutama dalam hal penyebaran data. Pada variabel Glucose, distribusi setelah imputasi tetap mempertahankan bentuk umum distribusi awal, namun terlihat lebih terpusat di sekitar nilai rata-rata. Hal ini menunjukkan bahwa metode mean cenderung mengisi nilai yang hilang dengan nilai tengah sehingga variasi data sedikit berkurang. Pada variabel BloodPressure, perubahan distribusi terlihat cukup jelas di mana setelah imputasi, data menjadi lebih terkonsentrasi di sekitar nilai rata-rata dan penyebaran menjadi lebih sempit. Hal ini mengindikasikan bahwa imputasi mean mengurangi variasi alami data. Kondisi yang lebih mencolok terjadi pada SkinThickness, di mana setelah imputasi muncul lonjakan frekuensi yang tinggi pada satu titik tertentu (sekitar nilai mean), sehingga distribusi menjadi kurang natural dan terlihat menumpuk.

Fenomena yang sama juga terlihat pada variabel Insulin, di mana setelah imputasi terdapat peningkatan frekuensi yang sangat tinggi pada nilai tertentu, yang menunjukkan bahwa banyak nilai hilang diisi dengan nilai rata-rata yang sama. Hal ini menyebabkan distribusi menjadi tidak realistis dan kehilangan pola aslinya yang sebelumnya cukup menyebar. Sementara itu, pada variabel BMI, perubahan yang terjadi relatif kecil karena sejak awal distribusinya sudah cukup stabil, meskipun tetap terlihat adanya sedikit pemusatan data di sekitar nilai mean. Secara keseluruhan, imputasi menggunakan mean memang sederhana dan mudah diterapkan, namun memiliki kelemahan yaitu dapat mengurangi variasi data dan menciptakan distribusi yang kurang alami, terutama pada fitur dengan jumlah missing value yang tinggi. Hal ini dapat berdampak pada performa model karena informasi penting dalam variasi data menjadi berkurang. Oleh karena itu, dibandingkan dengan metode seperti KNN, imputasi mean cenderung kurang mampu mempertahankan karakteristik asli data.


4.4 Hasil Perbandingan Metode

4.4.1 Tabel Perbandingan Peforma

**		Metode	Accuracy	Recall	F1-Score
0		Mean	0.785714	0.629630	0.673267
1		MICE	0.753247	0.592593	0.627451
2		KNN (k=5)	0.733766	0.555556	0.594059
3		Baseline (drop NA)	0.742857	0.571429	0.571429

Berdasarkan tabel 2, metode Mean Imputation menghasilkan F1-Score tertinggi sebesar 0.673267, diikuti oleh MICE (0.627451) dan KNN (0.594059). Baseline tanpa imputasi hanya memperoleh F1-Score 0.571429, menunjukkan peningkatan sebesar 17.8% setelah penerapan Mean Imputation. Mean Imputation mengungguli metode lain karena merupakan metode sederhana yang tidak mengubah distribusi data secara drastis, cocok untuk data dengan pola missing value yang MCAR (Missing Completely At Random) atau saat data yang hilang tidak memiliki korelasi kuat dengan fitur lain. Dengan parameter default dari RandomForestClassifier, Mean Imputation mampu mempertahankan informasi penting tanpa menambahkan kompleksitas yang tidak perlu, yang terkadang bisa terjadi dengan metode yang lebih kompleks pada dataset tertentu.


4.4.2 Visualisasi Perbandingan



Berdasarkan gambar perbandingan metrik evaluasi, terlihat bahwa metode imputasi memberikan pengaruh yang berbeda terhadap performa model klasifikasi. Dari tiga metrik yang digunakan yaitu Accuracy, Recall, dan F1-Score, metode imputasi mean menunjukkan hasil terbaik dibandingkan metode lainnya. Nilai akurasi tertinggi dicapai oleh metode mean (sekitar 0,78), diikuti oleh MICE, baseline (drop NA), dan KNN yang memiliki nilai paling rendah di antara keempat metode. Pada metrik Recall, yang penting untuk mengukur kemampuan model dalam mendeteksi kelas positif (diabetes), metode mean kembali menunjukkan performa terbaik, diikuti oleh MICE, baseline, dan KNN. Hal ini menunjukkan bahwa imputasi mean mampu membantu model dalam mengenali lebih banyak kasus positif dibandingkan metode lainnya.

Sementara itu, pada metrik F1-Score, yang merupakan keseimbangan antara precision dan recall, metode mean tetap unggul dengan nilai tertinggi, diikuti oleh


MICE, KNN, dan baseline. Secara keseluruhan, dapat disimpulkan bahwa metode imputasi mean memberikan performa model yang paling baik pada dataset ini, meskipun secara teori metode ini memiliki kelemahan dalam mempertahankan distribusi data. Di sisi lain, metode seperti KNN dan MICE yang lebih kompleks justru tidak memberikan peningkatan performa yang signifikan pada kasus ini. Hal ini menunjukkan bahwa pemilihan metode imputasi tidak selalu harus yang paling kompleks, melainkan perlu disesuaikan dengan karakteristik dataset dan tujuan analisis.



Berdasarkan grafik ROC Curve perbandingan metode imputasi, terlihat bahwa seluruh metode memiliki performa klasifikasi yang cukup baik karena kurva ROC masing-masing berada jauh di atas garis diagonal (random classifier). Garis diagonal tersebut merepresentasikan model acak, sehingga semakin jauh kurva dari garis tersebut dan semakin mendekati sudut kiri atas, maka semakin baik kemampuan model dalam membedakan antara kelas positif dan negatif. Dari nilai AUC (Area Under Curve) yang ditampilkan, metode imputasi Mean dan MICE memiliki performa terbaik dengan nilai AUC sebesar 0,82. Hal ini menunjukkan bahwa kedua metode tersebut memiliki kemampuan paling baik dalam memisahkan kelas diabetes dan non-diabetes. Sementara itu, metode Baseline (drop NA) dan KNN memiliki nilai AUC yang sedikit lebih rendah yaitu sebesar 0,81, namun perbedaannya tidak terlalu signifikan.

Secara visual, kurva dari metode Mean dan MICE cenderung berada sedikit di atas metode lainnya pada sebagian besar rentang False Positive Rate, yang mengindikasikan performa yang lebih konsisten dalam meningkatkan True Positive Rate. Namun demikian, karena selisih nilai AUC antar metode relatif kecil, dapat disimpulkan bahwa semua metode imputasi yang digunakan memberikan performa yang hampir sebanding dalam konteks klasifikasi ini. Secara keseluruhan, metode

Mean dan MICE dapat dianggap sebagai pilihan terbaik berdasarkan evaluasi ROC Curve, namun metode lain seperti KNN dan baseline juga masih cukup kompetitif. Hal ini menunjukkan bahwa pemilihan metode imputasi perlu mempertimbangkan tidak hanya performa model, tetapi juga kompleksitas metode dan efisiensi komputasi.



Berdasarkan gambar confusion matrix untuk setiap metode imputasi, dapat dianalisis bagaimana performa model dalam mengklasifikasikan data ke dalam kelas negatif (tidak diabetes) dan positif (diabetes). Pada metode Baseline (drop NA), model mampu mengklasifikasikan 40 data sebagai true negative dan 12 data sebagai true positive, dengan kesalahan berupa 9 false positive dan 9 false negative. Hal ini menunjukkan bahwa meskipun cukup seimbang, jumlah data yang digunakan lebih sedikit sehingga performanya terbatas. Pada metode imputasi Mean, terlihat peningkatan jumlah data yang benar terklasifikasi, dengan 87 true negative dan 34 true positive. Namun, terdapat juga peningkatan kesalahan, yaitu 13 false positive dan 20 false negative. Meskipun demikian, metode ini tetap memberikan hasil yang paling baik secara keseluruhan karena mampu mengenali lebih banyak kasus positif dibandingkan metode lainnya.

Sementara itu, metode KNN ($k=5$) menghasilkan 83 true negative dan 30 true positive, dengan 17 false positive dan 24 false negative. Dibandingkan metode mean, KNN cenderung menghasilkan lebih banyak kesalahan, terutama dalam bentuk false negative, yang berarti lebih banyak kasus diabetes yang tidak terdeteksi oleh model. Pada metode MICE, hasil yang diperoleh adalah 84 true negative dan 32 true positive, dengan 16 false positive dan 22 false negative. Performa metode ini berada di antara mean dan KNN, di mana mampu memberikan hasil yang cukup baik namun masih belum melampaui metode mean. Secara keseluruhan, dapat disimpulkan bahwa metode imputasi mean memberikan performa terbaik dalam klasifikasi, terutama dalam hal meningkatkan jumlah prediksi yang benar pada kedua kelas. Namun, semua metode masih menghadapi tantangan dalam mengurangi false negative, yang penting

untuk diperhatikan karena berkaitan dengan kasus pasien diabetes yang tidak terdeteksi.

4.5 Pembahasan

Metode Mean Imputation menghasilkan F1-Score terbaik sebesar 0.673267 karena mekanisme pengisian nilai hilang menggunakan rata-rata mampu menjaga stabilitas distribusi data tanpa menambah kompleksitas model. Berbeda dengan metode KNN yang bergantung pada kedekatan antar data dan cenderung sensitif terhadap noise, serta MICE yang lebih kompleks dan iteratif, metode mean justru memberikan performa yang lebih optimal pada dataset ini. Hal ini menunjukkan bahwa pada dataset dengan pola distribusi tertentu, pendekatan sederhana dapat bekerja lebih efektif dibandingkan metode yang lebih kompleks.

Meskipun metode mean memberikan recall tertinggi sebesar 0.629630, pendekatan ini memiliki keterbatasan karena cenderung menyederhanakan variasi data dengan menghasilkan nilai yang terpusat di sekitar rata-rata. Hal ini terlihat pada visualisasi distribusi setelah imputasi, di mana terjadi penumpukan nilai pada fitur seperti SkinThickness dan Insulin. Namun, dalam konteks dataset ini, kemampuan model dalam mendeteksi kelas positif (recall) tetap menjadi aspek penting, sehingga penggunaan mean masih dapat diterima karena mampu menjaga keseimbangan antara recall dan F1-score.

Baseline tanpa imputasi (drop NA) memperoleh accuracy sebesar 0.742857, namun recall hanya sebesar 0.571429, yang menunjukkan bahwa model kurang optimal dalam mendeteksi kelas positif. Setelah penerapan Mean Imputation, recall meningkat menjadi 0.629630 (peningkatan sekitar 10.19%), serta diikuti peningkatan pada F1-score. Hal ini menunjukkan bahwa penanganan missing value melalui imputasi memiliki peran penting dalam meningkatkan performa model, terutama dalam mendeteksi kasus positif secara lebih akurat.

DAFTAR PUSTAKA

- [1] K. Alnowaiser, "Improving Healthcare Prediction of Diabetic Patients Using KNN Imputed Features and Tri-Ensemble Model," in IEEE Access, vol. 12, pp. 16783-16793, 2024, doi: 10.1109/ACCESS.2024.3359760.
- [2] K. Psychogyios, L. Ilias, C. Ntanos and D. Askounis, "Missing Value Imputation Methods for Electronic Health Records," in IEEE Access, vol. 11, pp. 21562-21574, 2023, doi: 10.1109/ACCESS.2023.3251919.
- [3] Joel, L.O., Doorsamy, W. & Paul, B.S. A comparative study of imputation techniques for missing values in healthcare diagnostic datasets. Int J Data Sci Anal 20, 6357–6373 (2025). <https://doi.org/10.1007/s41060-025-00825-9>
- [4] M. Jena and S. Dehuri, "An Integrated Novel Framework for Coping Missing Values Imputation and Classification," in IEEE Access, vol. 10, pp. 69373-69387, 2022, doi: 10.1109/ACCESS.2022.3187412.
- [5] L. Jia, Z. Wang, S. Lv and Z. Xu, "PE_DIM: An Efficient Probabilistic Ensemble Classification Algorithm for Diabetes Handling Class Imbalance Missing Values," in IEEE Access, vol. 10, pp. 107459-107476, 2022, doi: 10.1109/ACCESS.2022.3212067.